Tecnológico de Monterrey

GALAXY10

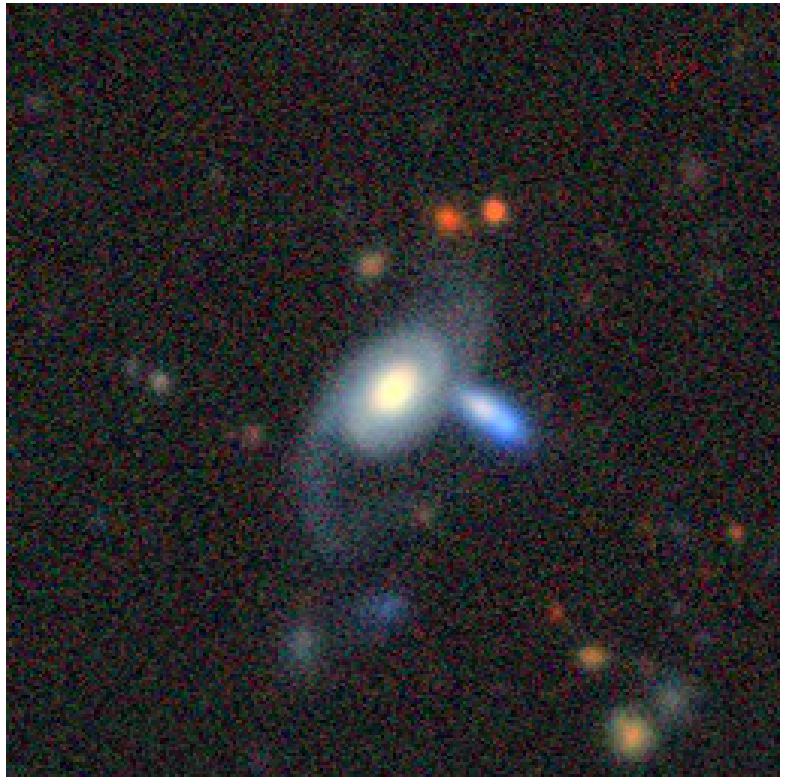
Segmentación y clasificación de galaxias

Otsu · split and merge · Qwen3-VL



1,000 imágenes de validación · 7 tratamientos

Problema y pregunta de investigación



Ruido, fondo y estructuras tenues

¿Cómo cambia el desempeño de Qwen al transformar y segmentar las imágenes de galaxias?

Interesa conservar la información morfológica.

Motivación del proyecto. Se comparan imágenes originales y seis tratamientos.

Objetivo e hipótesis

Objetivo

Comparar siete tratamientos
bajo las mismas condiciones.

Hipótesis

Mejorar el contraste o eliminar fondo podría ayudar.
También podría eliminar información morfológica.

La hipótesis plantea un posible beneficio y un posible costo del preprocesamiento.

Dataset Galaxy10 DECaLS

RGB de 256 × 256 píxeles · Diez clases morfológicas



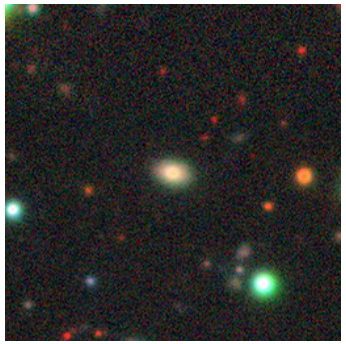
0 · Disturbed



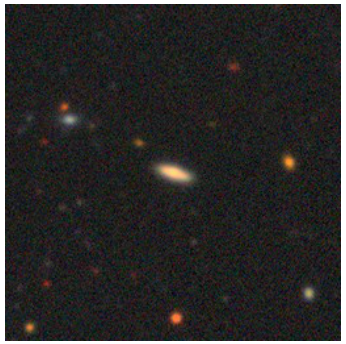
1 · Merging



2 · Round Smooth



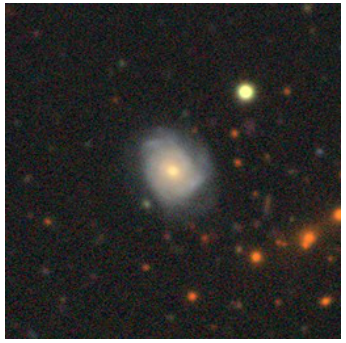
3 · In-between Smooth



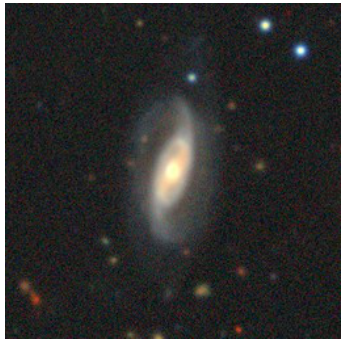
4 · Cigar-shaped Smooth



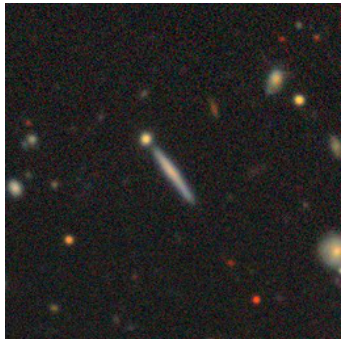
5 · Barred Spiral



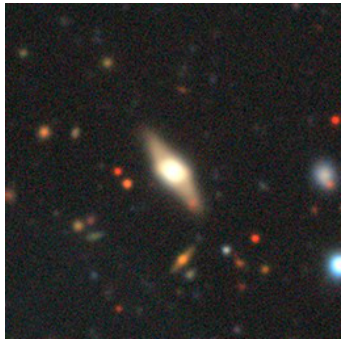
6 · Unbarred Tight Spiral



7 · Unbarred Loose Spiral



8 · Edge-on without Bulge



9 · Edge-on with Bulge

[4] Galaxy10 DECaLS. Ejemplos de validación: una imagen por clase.

Conjunto de validación

1,000

imágenes únicas

100 por clase

10 clases

Los siete tratamientos usan los mismos identificadores y etiquetas.

Propósito: comparar el desempeño de clasificación entre tratamientos.

Fuente: data/validacion_1000.csv. Balance comprobado: 100 imágenes en cada clase.

01

Método

Transformaciones, segmentación y clasificación con Qwen

Tecnológico de Monterrey

Diseño general del experimento

Imagen → **Tratamiento** → **Qwen** → **Predicción**

0 Original

1 Gaussian

2 CLAHE

3 Gaussian + Otsu

4 CLAHE + Otsu

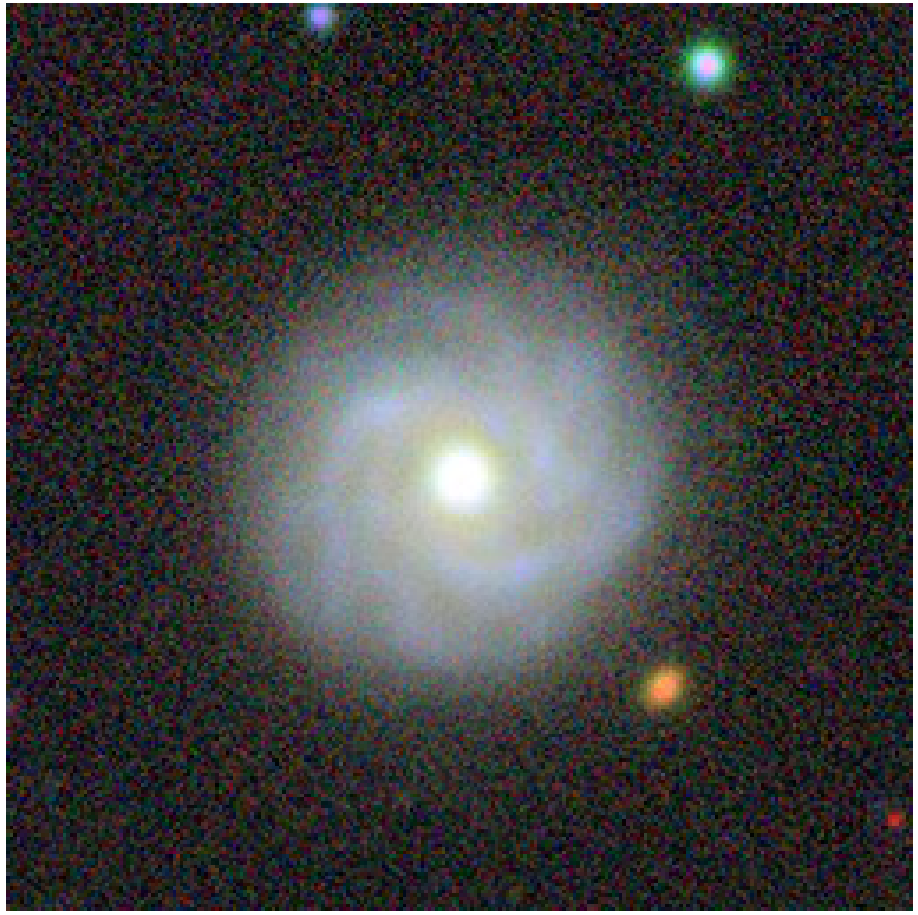
5 Gaussian + split and merge

6 CLAHE + split and merge

Etiquetas reales + predicciones = métricas registradas en MLflow

Siete condiciones implementadas en evaluar_qwen.py. Cada una evalúa 1,000 imágenes.

Imagen original: referencia de comparación



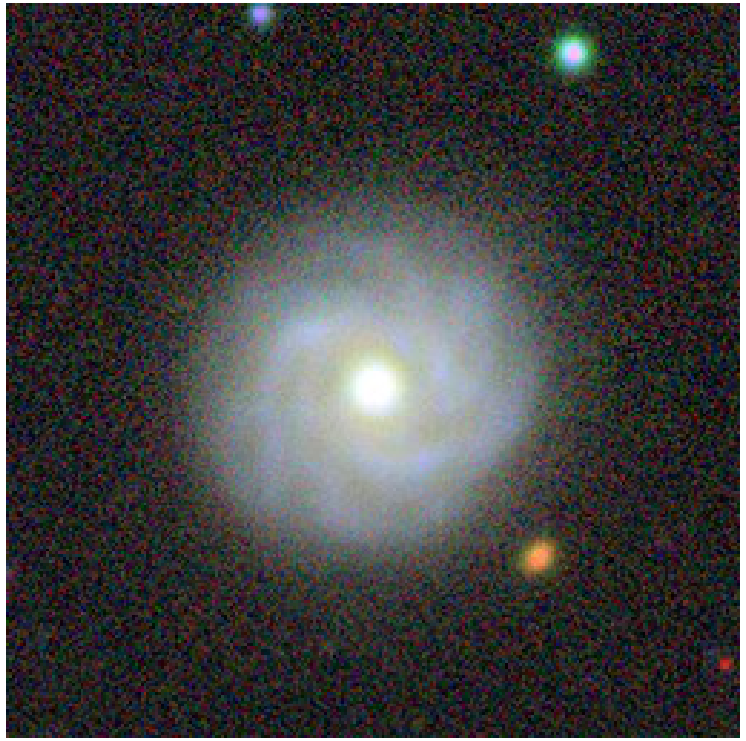
Información disponible

Color y forma
Brazos y distribución de luz
Fondo y objetos cercanos

Accuracy: 28.2 %
F1 macro: 0.2202

Tratamiento original: RGB sin modificar. Ejemplo de validación ID 10815.

Suavizado gaussiano



Original



Gaussian

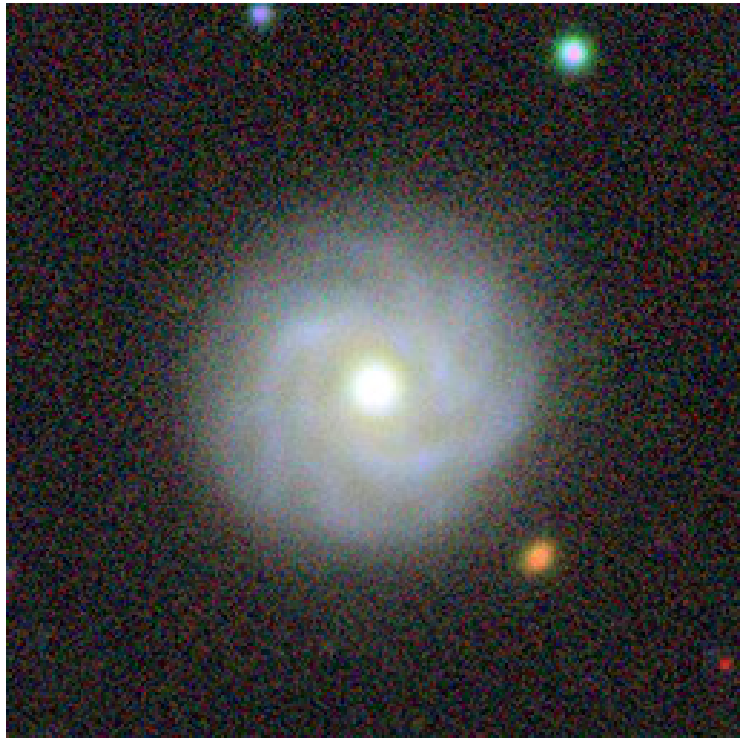
Reduce variaciones de alta frecuencia.

Puede suavizar detalles finos.

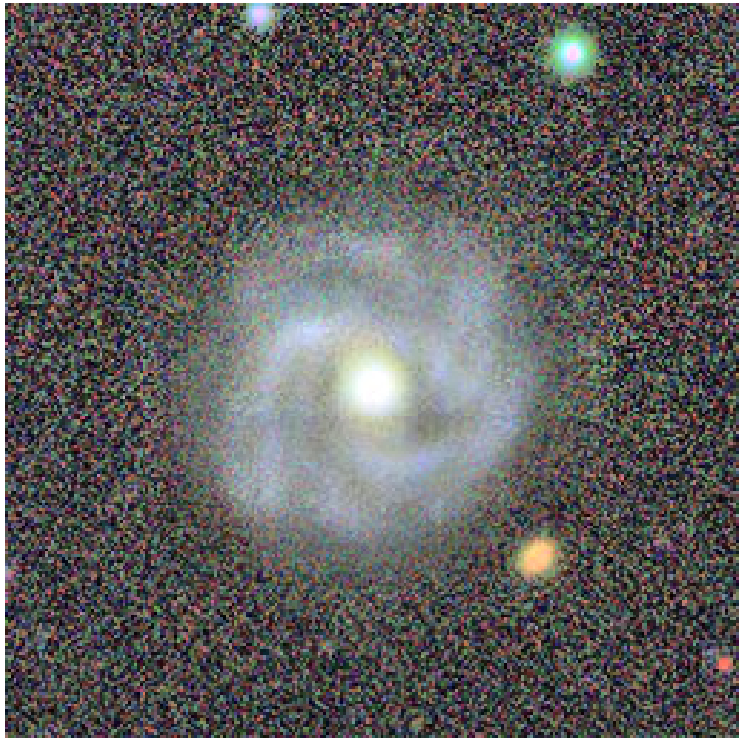
Kernel 5 × 5
Sigma = 1

Configuración del experimento: kernel 5 × 5, sigma = 1. Mismo ejemplo antes y después.

Realce de contraste con CLAHE



Original



CLAHE

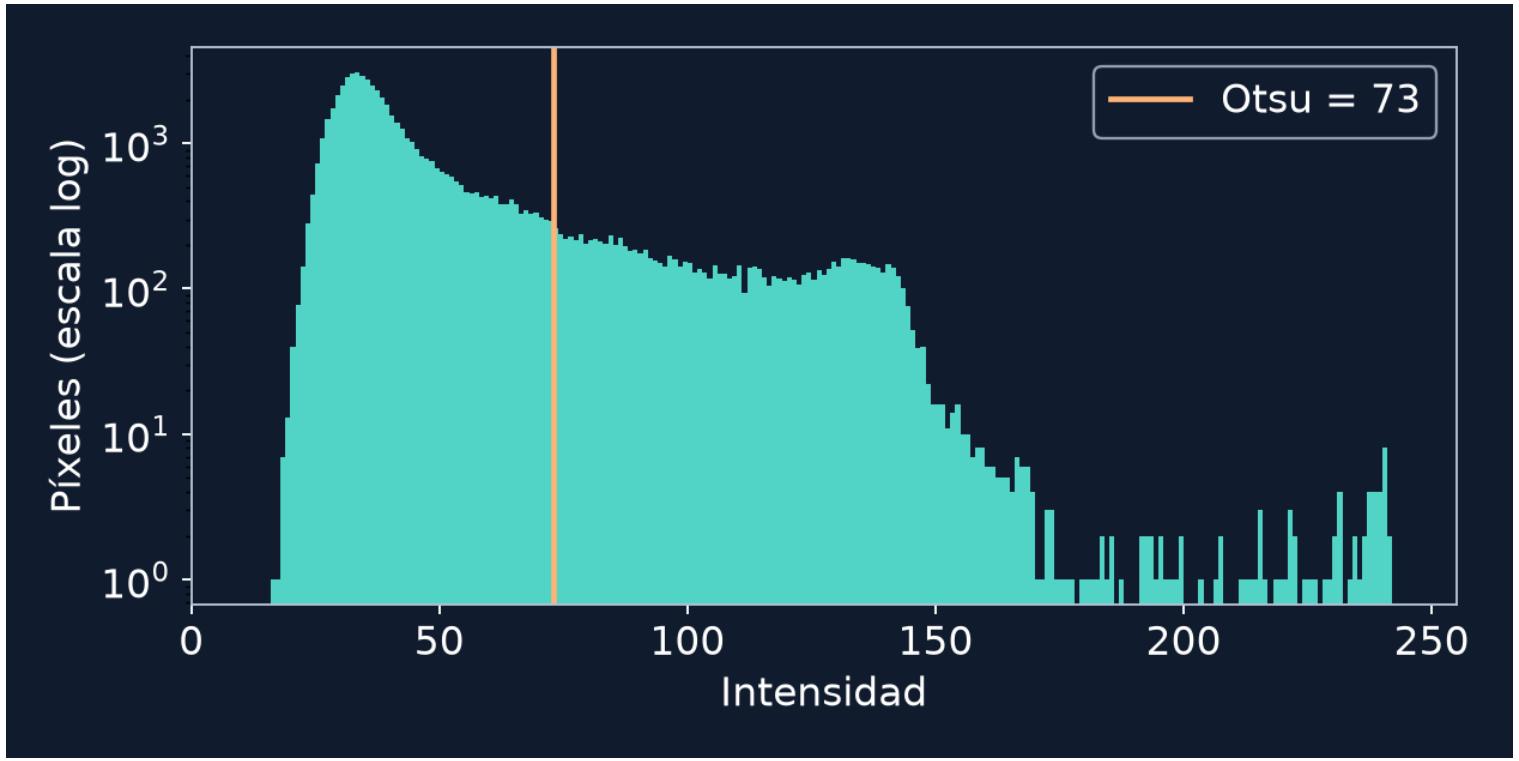
Realza contraste local en luminancia.

También puede realzar ruido.

LAB: canal L
Cuadrícula 8 × 8

CLAHE sobre el canal L en LAB. clipLimit = 2.0, tileGridSize = 8 × 8.

Segmentación mediante Otsu



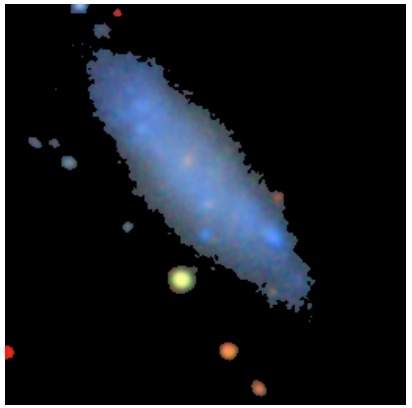
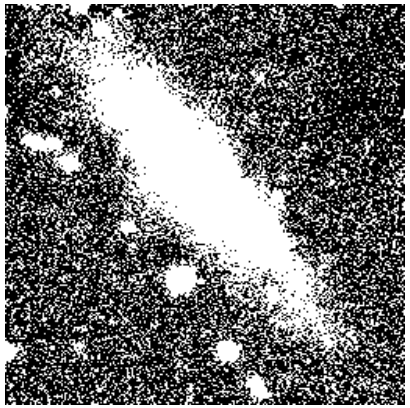
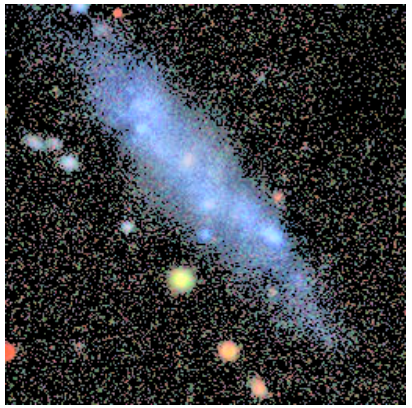


Máscara binaria

Un umbral global se calcula automáticamente para cada imagen.

[3, 5] Otsu maximiza la varianza entre clases. Ejemplo ID 14633 con Gaussian.

Gaussian + Otsu y CLAHE + Otsu

	Procesada	Máscara	RGB segmentada
Gaussian + Otsu			
CLAHE + Otsu			

Mismo ejemplo ID 14633. Qwen recibe la RGB segmentada, conservando sus colores.

Split and merge: artículo y fundamento

Horowitz y Pavlidis

1976

Picture Segmentation by
a Tree Traversal Algorithm

Dividir regiones heterogéneas.
Fusionar regiones compatibles.

Motivación: segmentar con ruido y fronteras difusas.

Nuestra variante usa desviación estándar y una regla propia de primer plano.

[1] Horowitz y Pavlidis (1976). [2] Fu et al. (2013): aplicación con quadtree y grafo de adyacencia.

Formulación del problema de segmentación

P(S): max(S) - min(S) ≤ 2ε

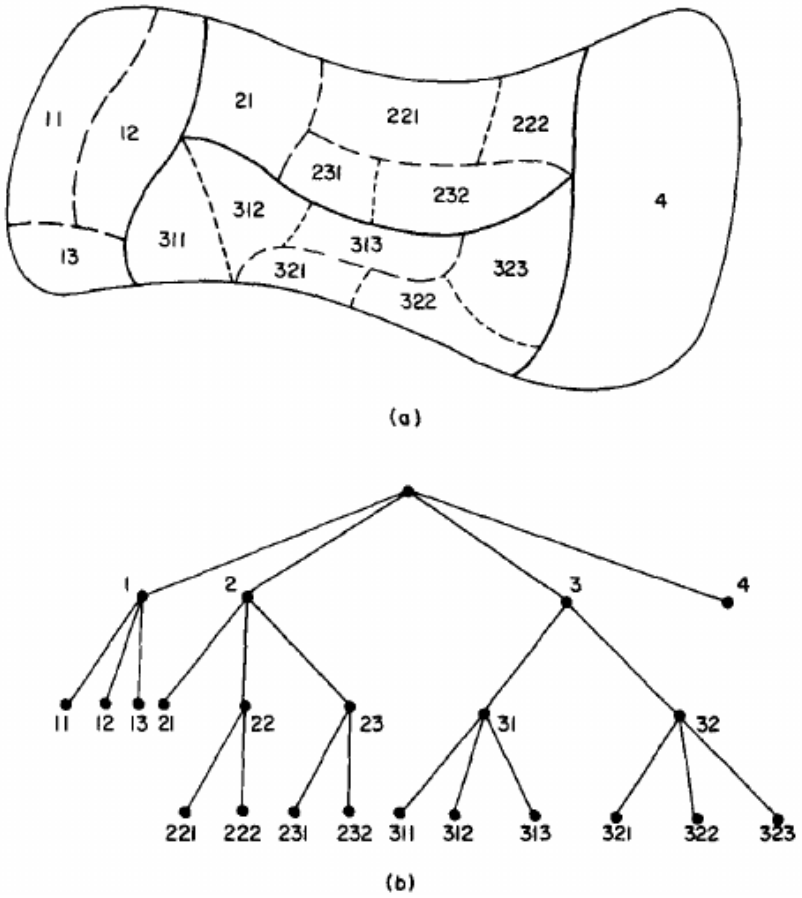
Existe una constante a con |I(p) - a| ≤ ε para todos los píxeles de S.

1. Las regiones cubren toda la imagen.
2. Las regiones son disjuntas.
3. Cada región satisface P.
4. La unión de dos regiones adyacentes no satisface P.

La partición resultante no es necesariamente única ni tiene el mínimo global de regiones.

Horowitz y Pavlidis (1976). Journal of the ACM 23(2). Sección 2, pp. 370-372.

Árbol y cutset: representación de la partición



Cada nodo representa una región.
La raíz representa toda la imagen.

El **cutset** selecciona nodos que forman la partición activa.

La implementación almacena posición, tamaño, máximo y mínimo de cada bloque activo.

Horowitz y Pavlidis (1976). Journal of the ACM 23(2). Secciones 2 y 4, pp. 370-374. Figura 2: © 1976 ACM.

Procedimiento original: recorrido del árbol

01 Inicializar Elegir un nivel intermedio l0 y calcular los máximos y mínimos.

02 Fusionar Reunir cuatro bloques hermanos si la unión satisface P.

03 Dividir Subdividir los bloques que exceden la tolerancia.

04 Agrupar Unir vecinos compatibles de ramas o niveles distintos.

El nivel inicial busca reducir el trabajo de división y fusión. Nuestro código parte de la raíz.

Horowitz y Pavlidis (1976). Journal of the ACM 23(2). Secciones 3-4, pp. 372-374.

Agrupamiento, limpieza y contornos

Agrupamiento lateral

Elimina fronteras impuestas por el árbol. Examina bloques adyacentes aunque no compartan padre.

Limpieza de regiones

Absorbe regiones pequeñas en vecinos de media similar y combina regiones de medias cercanas.

Después extrae contornos cerrados y compacta tramos lineales mediante sus extremos.

El agrupamiento depende del orden.
La limpieza por medias relaja el criterio de máximos y mínimos.

Horowitz y Pavlidis (1976). Journal of the ACM 23(2). Secciones 5-6, pp. 375-377.

Experimentos y resultados del artículo

64 × 64 · 7 bits · IBM 360/91 · PL/I y Fortran H

Caso	Tras agrupar	Tras limpiar	Tiempo (s)
Rostro	148	13	4.59
Radiografía de tórax	49	11	1.45
Paisaje	186	13	3.62
Cromosoma	115	6	3.12

La tabla describe reducción y organización de regiones.
Esos tiempos no se comparan directamente con nuestra GPU ni son métricas de clasificación.

Horowitz y Pavlidis (1976). Journal of the ACM 23(2). Sección 7 y Tabla I, p. 378. Tiempos reportados: dominados por E/S, ±10 %.

Conclusiones y lectura crítica del artículo

Contribución

Reducir y organizar la imagen antes del reconocimiento semántico.
Reutilizar la estructura entre tipos de imágenes.

Límites de la evidencia

Ejemplos de baja resolución.
Evaluación visual y estadísticas de procesamiento.

El trabajo reconoce que la segmentación requiere información semántica para interpretar objetos.

Evidencia descriptiva de segmentación y costo computacional.
La clasificación de Galaxy10 necesita su propia evaluación.

Horowitz y Pavlidis (1976). Journal of the ACM 23(2). Sección 8, pp. 378 y 387.

Artículo original frente a nuestra variante

Decisión	Artículo de 1976	Proyecto Galaxy10
Homogeneidad	Rango de intensidades ≤ 2ε	Desviación estándar ≤ 10
Inicialización	Nivel intermedio del árbol	Imagen completa, desde la raíz
Fusión	Hermanos y agrupamiento lateral	Vecinos con cola de prioridad
Limpieza y contornos	Etapas específicas posteriores	Sin esas etapas del artículo
Primer plano	Partición general de la imagen	Regla propia basada en el borde

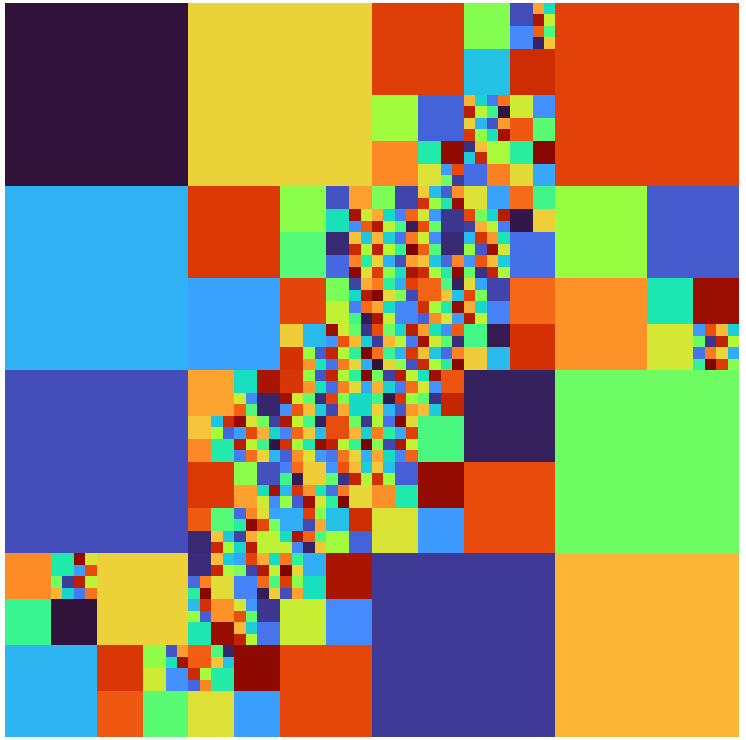
Compartimos la familia split and merge. La evaluación incluye nuestras decisiones adicionales.

Horowitz y Pavlidis (1976). Journal of the ACM 23(2). Artículo: secciones 2-6. Proyecto: segmentacion.py y evaluar_qwen.py.

Split: división de regiones



Intensidad



Bloques del quadtree

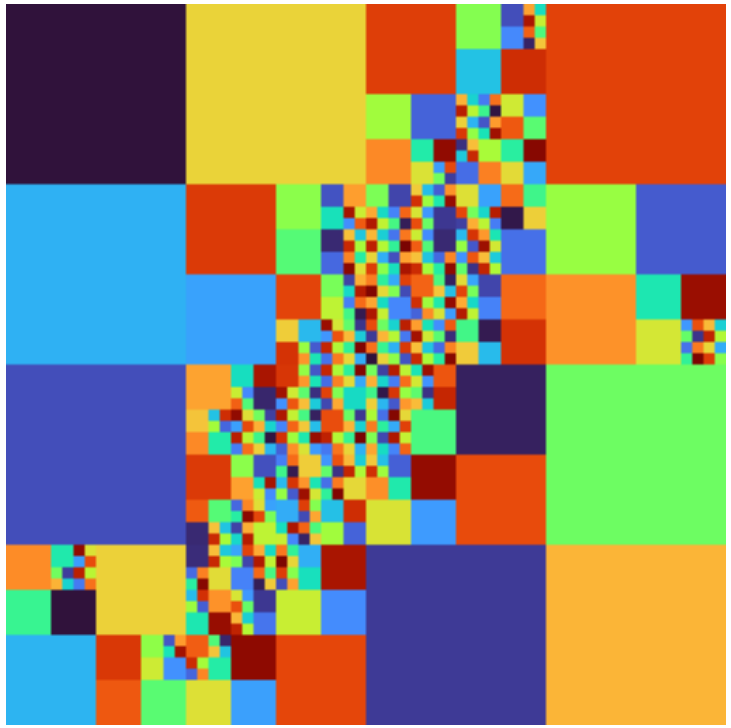
σ(R) > 10
Dividir en cuatro.

El tamaño mínimo detiene la división.

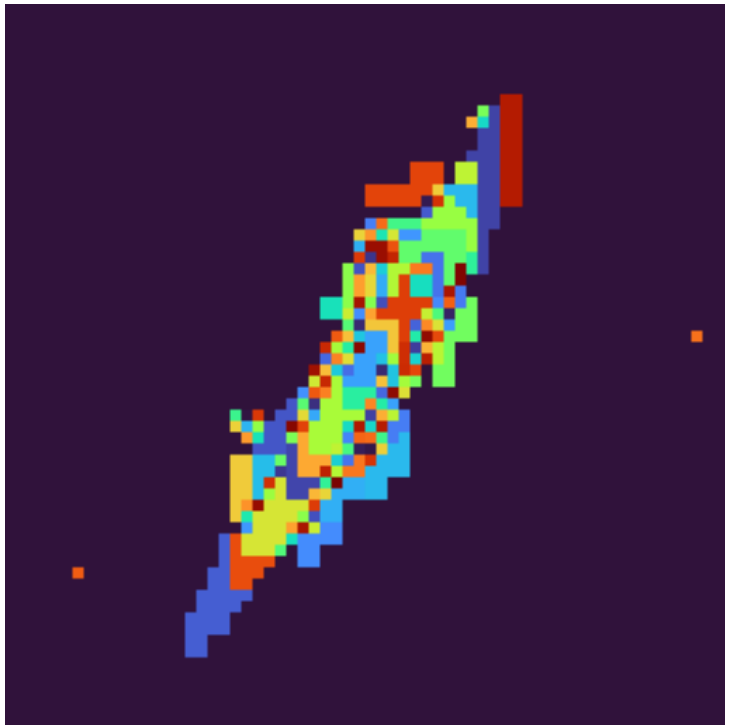
Puede quedar heterogeneidad.

Variante del proyecto: σ(R) > 10 y cuatro hijos de al menos 4 × 4 píxeles. ID 15658.

Merge: fusión de regiones



Antes de fusionar



Después de fusionar

$\sigma(\text{A unida con B}) \leq 10$

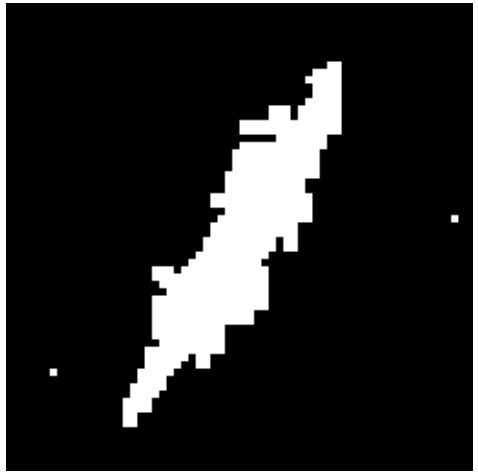
Prioridad: menor desviación de la unión.

Actualizar vecinos, sumas y conteos.

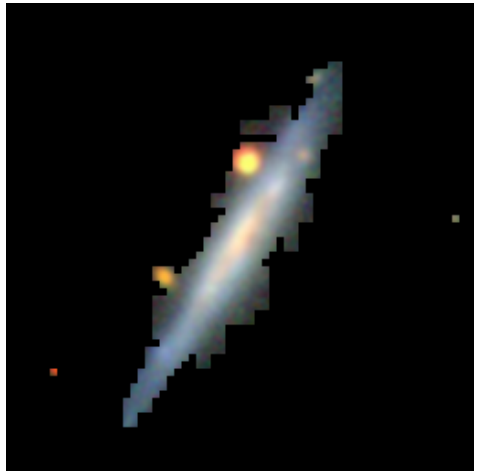
Adyacencia por borde, también entre hojas de distintas ramas del quadtree. ID 15658.

Máscara y variantes de split and merge

Gaussian + split and merge

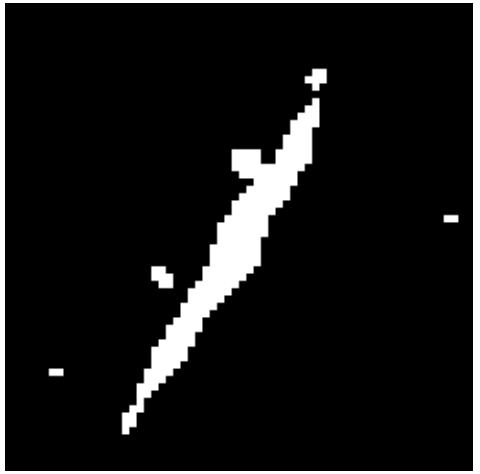


Máscara

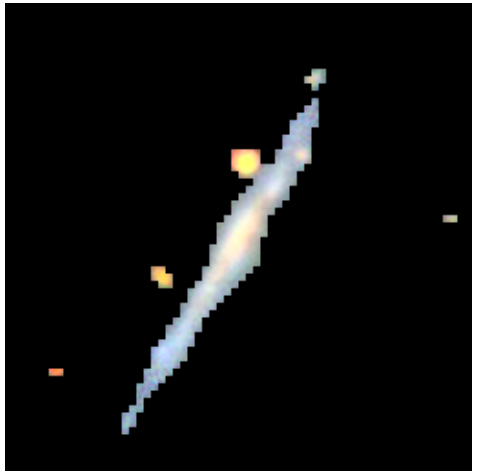


RGB segmentada

CLAHE + split and merge



Máscara



RGB segmentada

tau = 10 · min_size = 4 · fondo_k = 3

Umbral = mediana(borde) + 3 × max(1, 1.4826 × MAD)

Regla propia de primer plano: supone un perímetro representativo del fondo. Ejemplo ID 15658.

Clasificación con Qwen3-VL

Qwen3-VL-4B-Instruct

4B parámetros
Cuantización NF4 de 4 bits
NVIDIA RTX 4060

Prompt (extracto)

Classify the morphology of the main galaxy near the center of the image.

Return ONLY one digit from 0 to 9.
Do not explain.

Salida esperada: un dígito de clase.
Ejemplo guardado: ID 14633, etiqueta 8, predicción 8.

Modelo y prompt reales del experimento. Categorías completas en el anexo técnico.

Control experimental y MLflow

7,000

clasificaciones

1,000 imágenes únicas
7 tratamientos

Mismo modelo y prompt
Mismos identificadores
Generación determinista

Accuracy: fracción de aciertos.
F1 macro: promedio de F1 con igual peso por clase.

Siete ejecuciones completas · Cero respuestas inválidas

Experimento: Galaxy10_Qwen3VL_Otsu. Parámetros, predicciones, métricas y matrices guardados.

02

Resultado

Comparación de siete tratamientos y análisis de MLflow



Tecnológico de Monterrey

Resultados de los siete tratamientos

Tratamiento	Accuracy	F1 macro
CLAHE + Otsu	31.3 %	0.2472
CLAHE	31.0 %	0.2387
Gaussian	28.6 %	0.2224
Original	28.2 %	0.2202
Gaussian + Otsu	23.0 %	0.1698
Gaussian + split and merge	21.8 %	0.1565
CLAHE + split and merge	16.2 %	0.0926



Mejor F1 macro de validación: CLAHE + Otsu, 0.2472.

Fuente: comparacion_mlflow.csv. Tabla y gráfica de F1 macro, sobre la misma validación.

Métricas globales registradas en MLflow

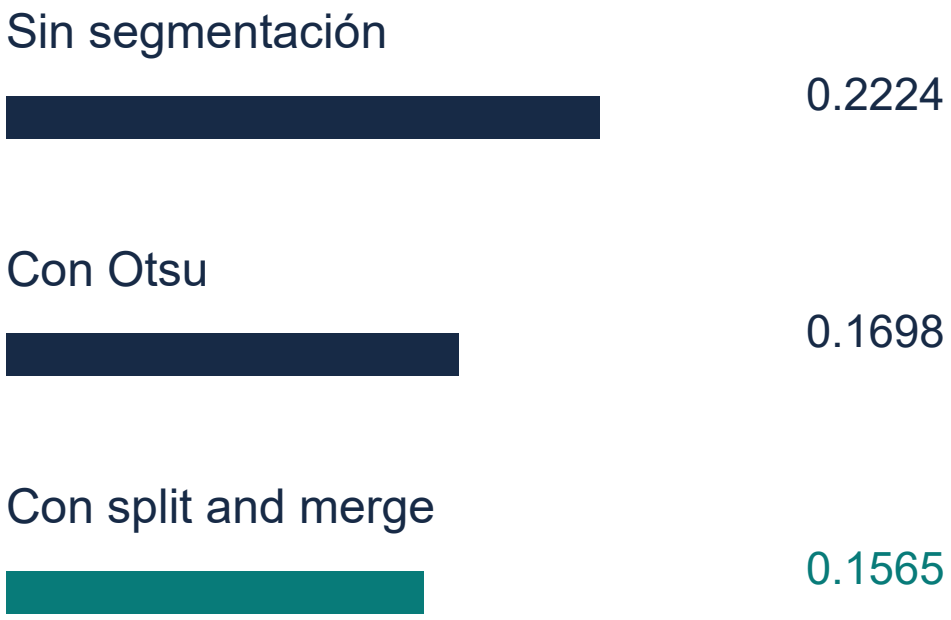
Tratamiento	Accuracy	Precisión	Recall	F1 macro
Original	0.282	0.242	0.282	0.2202
Gaussian	0.286	0.286	0.286	0.2224
CLAHE	0.310	0.252	0.310	0.2387
Gaussian + Otsu	0.230	0.229	0.230	0.1698
CLAHE + Otsu	0.313	0.344	0.313	0.2472
Gaussian + split and merge	0.218	0.202	0.218	0.1565
CLAHE + split and merge	0.162	0.160	0.162	0.0926

CLAHE + Otsu: 313 aciertos, precisión macro 0.344 y F1 macro 0.2472.

Promedios macro sobre diez clases. Cada ejecución tiene 1,000 predicciones válidas.

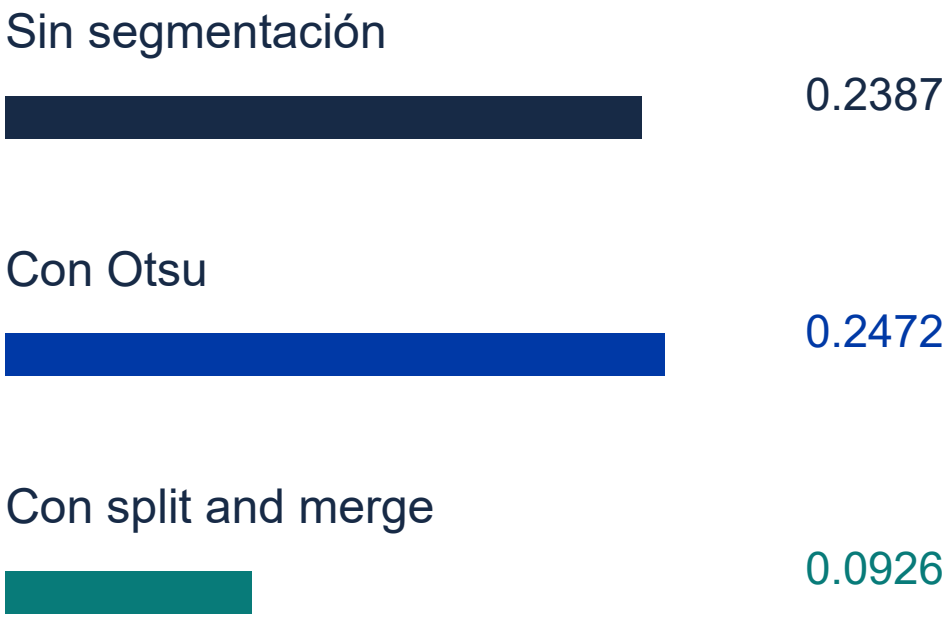
Efecto de agregar segmentación

Gaussian



Split and merge: -0.0660 de F1

CLAHE



Split and merge: -0.1461 de F1

Cambios de F1 macro respecto a la transformación sin segmentación. Resultados descriptivos.

Qué cambió en las mismas imágenes

Original frente a CLAHE + Otsu

94

errores corregidos

63

aciertos perdidos

31

aciertos netos

219 imágenes correctas en ambos tratamientos.
624 imágenes incorrectas en ambos.

Accuracy: +3.1 puntos porcentuales · F1 macro: +0.0270

Conteos derivados de predictions.csv. Comparaciones emparejadas, no una prueba de significancia.

Resultados por clase y errores

CLAHE + Otsu

	0	1	2	3	4	5	6	7	8	9
0	2	17	55	0	7	3	0	1	9	6
1	1	61	29	0	5	4	0	0	0	0
2	0	1	99	0	0	0	0	0	0	0
3	0	3	79	0	8	1	0	0	1	8
4	0	0	11	0	33	1	0	0	33	22
5	0	7	37	0	5	30	4	3	9	5
6	0	1	44	0	7	33	1	3	5	6
7	0	6	49	0	4	18	1	10	7	5
8	0	0	0	0	34	0	0	0	60	6
9	0	3	7	0	27	5	0	0	41	17

Clase predicha (0-9)

CLAHE + split and merge

	0	1	2	3	4	5	6	7	8	9
0	5	1	77	0	11	5	0	1	0	0
1	21	2	66	0	1	10	0	0	0	0
2	0	0	100	0	0	0	0	0	0	0
3	4	0	84	0	7	2	0	0	0	3
4	11	0	52	0	25	2	0	0	6	4
5	2	1	56	0	12	21	0	2	1	5
6	1	2	71	0	5	15	0	1	1	4
7	6	0	78	0	2	8	0	2	0	4
8	9	1	2	0	57	25	0	0	5	1
9	13	0	18	0	37	27	0	0	3	2

Clase predicha (0-9)

Round Smooth (clase 2): 410 y 604 predicciones, respectivamente.

Filas: clase real. Columnas: clase predicha. Cada fila contiene 100 galaxias. Clases 0-9 en la diapositiva 4.

F1 por clase: dónde persisten los errores

	Original	G	C	G + O	C + O	G + SM	C + SM
0 · Disturbed	0.000	0.000	0.000	0.018	0.039	0.060	0.058
1 · Merging	0.510	0.510	0.628	0.447	0.613	0.361	0.037
2 · Round Smooth	0.321	0.336	0.388	0.332	0.388	0.352	0.284
3 · In-between Smooth	0.000	0.000	0.000	0.000	0.000	0.000	0.000
4 · Cigar-shaped Smooth	0.296	0.249	0.290	0.275	0.287	0.174	0.195
5 · Barred Spiral	0.289	0.338	0.297	0.226	0.308	0.275	0.195
6 · Unbarred Tight Spiral	0.000	0.037	0.019	0.000	0.019	0.000	0.000
7 · Unbarred Loose Spiral	0.037	0.038	0.102	0.000	0.171	0.000	0.038
8 · Edge-on without Bulge	0.579	0.563	0.521	0.315	0.453	0.239	0.086
9 · Edge-on with Bulge	0.171	0.153	0.143	0.084	0.194	0.104	0.033

Clase 3: F1 = 0 en los siete tratamientos.

Clase 6: F1 máximo de apenas 0.037.

G = Gaussian · C = CLAHE · O = Otsu · SM = split and merge. Soporte: 100 imágenes por clase.

Qué muestran las máscaras de segmentación

Tratamiento	Píxeles conservados	Componentes
Gaussian + Otsu	5.46 %	9.24
CLAHE + Otsu	33.58 %	2,000.64
Gaussian + split and merge	7.92 %	3.63
CLAHE + split and merge	2.94 %	6.53

Regiones antes y después de fusionar

Gaussian: 355 a 72

CLAHE: 4,060 a 3,970

Regiones del particionado y componentes de la máscara son conteos diferentes.

Porcentaje y componentes conectados de primer plano. Estadísticas descriptivas, sin IoU ni Dice.

Tiempos registrados en MLflow

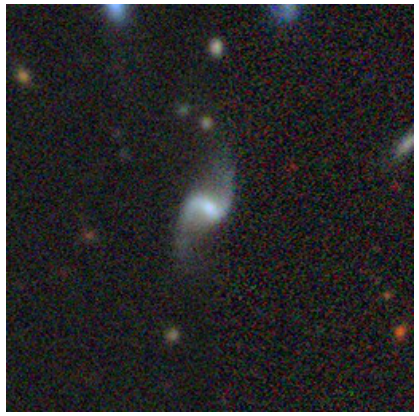
Tratamiento	Generación Qwen (ms)	Preproceso (ms)
Original	327.36	n/d
Gaussian	325.66	n/d
CLAHE	296.10	n/d
Gaussian + Otsu	309.00	n/d
CLAHE + Otsu	307.99	n/d
Gaussian + split and merge	296.27	24.98
CLAHE + split and merge	300.24	69.53

Preproceso medido para split and merge: Gaussian 24.98 ms, CLAHE 69.53 ms.
n/d: esa medición no se registró en los cinco tratamientos anteriores.

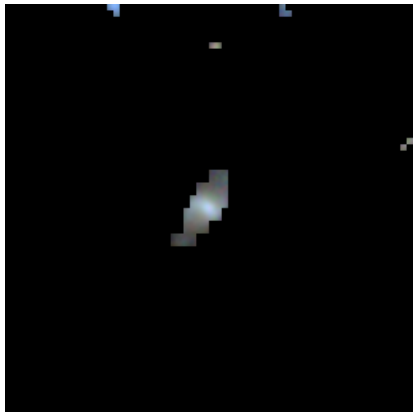
Medias por imagen. La generación de Qwen no representa el tiempo total del pipeline.

Limitaciones y análisis visual

ID 8101 · Espiral barrada



Original

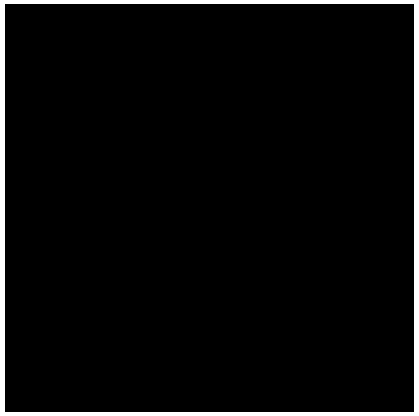


Segmentada

ID 5893 · Máscara vacía



Original



Segmentada

Estructura tenue recortada y estrellas externas conservadas.
Gaussian: 5 máscaras vacías y 1 llena. CLAHE: 0 vacías.

Sin IoU/Dice ni prueba de significancia. La pérdida de estructura es una hipótesis explicativa.

Gaussian + split and merge. Ejemplos seleccionados para mostrar fallos, sin máscaras de referencia.

03

Conclusiones

Lo que muestran los resultados de validación

Tecnológico de Monterrey

Conclusiones y transición a la demo

CLAHE + Otsu obtuvo el mejor resultado.

Accuracy: 31.3 % · F1 macro: 0.2472

Las variantes evaluadas de split and merge redujeron el desempeño respecto a sus transformaciones base.

Demo en Colab: segmentar tres galaxias y consultar los resultados completos de los siete tratamientos.

Alcance de las conclusiones: 1,000 imágenes de validación, parámetros y modelo evaluados.

Referencias científicas

[1] Horowitz, S. L., & Pavlidis, T. (1976). Picture Segmentation by a Tree Traversal Algorithm. Journal of the ACM, 23(2), 368-388.

https://doi.org/10.1145/321941.321956

[2] Fu, G., Zhao, H., Li, C., & Shi, L. (2013). Segmentation for High-Resolution Optical Remote Sensing Imagery Using Improved Quadtree and Region Adjacency Graph Technique. Remote Sensing, 5(7), 3259-3279.

https://doi.org/10.3390/rs5073259

[3] Otsu, N. (1979). A Threshold Selection Method from Gray-Level Histograms. IEEE Transactions on Systems, Man, and Cybernetics, 9(1), 62-66.

https://doi.org/10.1109/TSMC.1979.4310076

Datos, código e identidad institucional

[4] Galaxy10 DECaLS. Leung y Bovy. Zenodo.
https://doi.org/10.5281/zenodo.10845026

[5] OpenCV. Image Thresholding.
docs.opencv.org/4.x/d7/d4d/tutorial_py_thresholding.html

Evidencia: mlflow.db y resultados_qwen/.
Siete runs FINISHED. 1,000 predicciones por tratamiento.

Logo: archivo institucional del sitio oficial tec.mx.
Colores y lineamientos: bamboo.tec.mx.